

人工智能课程设计——课程作业 3

深度学习模块：手写数字识别与垃圾分类

一、实验背景

本次实验的背景基于深度学习领域的经典入门案例——LeNet5 模型与 MNIST 手写数字数据集，该组合因其结构简洁、逻辑清晰、易于复现而被誉为深度学习的“Hello World”，为理解卷积神经网络（CNN）的基本原理和图像分类任务奠定了基础。随着深度学习技术向实际应用场景扩展，单一的手写数字识别已无法满足复杂任务需求，尤其是在智慧城市与环保领域，垃圾分类亟需高效的智能识别技术。因此，本实验通过预训练的 MobileNetV2 模型在垃圾分类数据集上进行微调（Fine-Tune），旨在以较低的计算成本实现图像分类任务，帮助学习者掌握 MindSpore 框架的使用方法，理解不同微调策略（如冻结微调、全量微调、LoRA 等）的原理与适用场景，并探索轻量级网络在细分任务中的优化方向，为深度学习在实际场景中的落地积累实践经验。

二、实验内容

本次实验的实验内容主要围绕深度学习中的微调技术展开，以 MindSpore 框架为平台，以 MobileNetV2 模型和垃圾分类数据集为例，演示如何利用预训练模型进行迁移学习。实验首先介绍了深度学习中的经典“Hello World”案例——LeNet5 与 MNIST 手写数字识别，指出从头训练模型通常耗时且易出现过拟合，因此在实际任务中更倾向于使用预训练模型进行微调。在此基础上，实验要求学生加载在手写数字数据集上训练好的预训练模型，并在垃圾分类数据集上进行微调任务，具体包括复现并理解开源项目的代码原理与流程、编写类似代码实现模型加载与不同任务上的微调、尝试冻结微调、全量微调和 LoRA 微调等多种方式并对比其显存占用、准确率和训练时间，最后对模型进行改进以提升分类准确率，并在相同超参数下对比改进前后的效果。

三、LeNet5 + MNIST

核心代码原理

1. 局部感知与参数共享（卷积原理）

传统的全连接网络若直接处理图像，会导致权重参数爆炸且丢失空间结构信息。LeNet-5 采用卷积层（nn.Conv2d）来解决这一问题：

- **局部感知**：卷积核每次只关注图像的一个局部区域（如 5×5 ），用于提取边缘、线条等初级几何特征。
- **参数共享**：同一个卷积核在整张图像上滑动时，其权重矩阵是完全相同的。这大大减少了网络需要训练的参数量，同时也赋予了网络**平移不变性**（即数字在图片中央或角落都能被识别）。

2. 下采样与特征降维（池化原理）

代码中使用了最大池化层（nn.MaxPool2d），它的主要原理是在 2×2 的窗口内筛选出最大的响应值。

- **作用**：在保留核心特征（最显著的边缘或结构）的同时，将特征图的长宽

各缩减一半。这不仅能降低后续计算量，还能使网络对图像的轻微形变和位移更具鲁棒性。

3. 多分类交叉熵损失与动量优化

- **Softmax 交叉熵**: `nn.SoftmaxCrossEntropyWithLogits` 内部包含两步。第一步通过 `Softmax` 函数将网络最终输出的 10 个无边界实数 (Logits) 转化为概率分布 (和为 1); 第二步计算该概率与真实标签之间的交叉熵损失 (Cross Entropy Loss)。损失值越低, 代表网络预测得越准。
- **动量 (Momentum) 机制**: 在标准的随机梯度下降 (SGD) 基础上引入了“惯性”。它在更新权重时会考虑上一次的梯度方向, 公式逻辑为:

$$v_t = \gamma v_{t-1} + \eta g_t$$

$$W_t = W_{t-1} - v_t$$

这能帮助网络在梯度平坦的区域加速收敛, 并有效抑制参数更新过程中的震荡。

核心操作

1. 环境与数据预处理操作 (`create_dataset`)

- **静态图模式配置**: `context.set_context(mode=context.GRAPH_MODE, device_target="CPU")`。GRAPH_MODE 是 MindSpore 的编译模式, 它会在运行前将 Python 代码编译成计算图进行性能优化, 非常适合大规模训练。
- **数据打乱 (shuffle)**: 设置 `buffer_size=64`, 打破原始数据按顺序排列的规律, 确保每个 Batch 里的样本是随机的, 防止网络在训练时产生“偏见”或发生过拟合。
- **图像缩放与归一化 (transform)**:
 - `CV.Resize((32, 32))`: LeNet-5 的设计标准输入是 32×32 , 而 MNIST 原始图是 28×28 , 因此需要插值放大。
 - `CV.Rescale(1.0 / 255.0, 0)`: 将 $[0, 255]$ 的灰度级像素值压缩至 $[0.0, 1.0]$, 避免在前向传播中发生数值爆炸。
 - `CV.Normalize`: 利用 MNIST 标准均值 0.1307 和标准差 0.3081 实施标准化, 使输入数据符合正态分布, 有利于梯度平稳流动。
 - `CV.HWC2CHW()`: 把硬件常见的 (高、宽、通道) 格式调整为 AI 框架计算更高效的 (通道、高、宽) 维度顺序。

2. 网络结构操作 (LeNet5)

代码定义的网络严格遵循了 LeNet-5 的经典拓扑拓扑关系:

- `self.conv1 = nn.Conv2d(1, 6, 5, pad_mode='valid')`: 输入 1 个通道 (灰度图), 使用 6 个 5×5 的卷积核, 不进行零填充 (valid)。输入 32×32 经此操作后尺寸变为: $(32 - 5 + 1) = 28 \times 28$, 通道数变为 6。
- `self.max_pool2d`: 经 2×2 池化, 尺寸折半, 特征图变为 $14 \times 14 \times 6$ 。
- `self.conv2`: 输入 6 通道, 输出 16 通道, 卷积核 5×5 , 无填充。尺寸计算: $(14 - 5 + 1) = 10 \times 10$, 通道数变为 16。
- 再次池化后, 特征图最终缩减为 $5 \times 5 \times 16$ 。
- `self.flatten`: 全连接层无法直接接收三维特征图, 此操作将 $[16, 5, 5]$ 的多维张量展平为一维向量, 长度为 $16 \times 5 \times 5 = 400$ 。
- `self.fc1, self.fc2, self.fc3`: 通过三层密集的线性映射 (Dense 层), 神经元数量由 $400 \rightarrow 120 \rightarrow 84 \rightarrow 10$, 最终输出 10 个数字分类的得分。


算法流程

首先设置 MindSpore 框架的运行环境（CPU/GPU 及静态图模式）；接着下载并加载 MNIST 手写数字数据集，对图像进行缩放至 32×32 、归一化、标准化及维度转换等预处理，并按批次打乱；然后构建 LeNet5 网络结构，包含两个卷积-池化模块用于提取图像特征，以及三个全连接层用于分类输出；之后定义交叉熵损失函数和带动量的 SGD 优化器；将数据、网络、损失函数和优化器封装后开始训练，每次迭代执行前向传播计算损失、反向传播计算梯度，并更新网络参数；每个 epoch 结束后保存模型并输出损失值；最后在测试集上评估模型，计算分类准确率。整个流程实现了从原始图像输入到数字分类端到端的训练与验证。

训练的过程为：

```
加载训练集...
训练集批次数：1875
测试集批次数：312
开始训练...
epoch: 1 step: 1875, loss is 0.043667491525411606
epoch: 2 step: 1875, loss is 0.003951364662498236
epoch: 3 step: 1875, loss is 0.0011053925845772028
评估模型...
测试集准确率：98.3574%
```

我还写了一个可视化的程序来查看最后的结果。



由此说明最后的训练结果的正确性很高。

四、跨任务模型加载与多分类微调

本部分主要实现的是将基于 MNIST 单通道黑白数据集预训练的 LeNet5 特征提取能力，迁移到包含包含 26 类高维彩色图像的现代垃圾分类任务中，验证经典骨干网络在异构下游任务中的泛化性能与收敛效率。

在处理从“单通道低维黑白手写数字”到“三通道高维彩色垃圾图片”的跨越时，本实验拒绝了传统的粗暴灰度化（Grayscale）降维方案，完成了以下关键技术升级：

1、三通道彩色保留设计

传统做法常通过数据降维将彩色图强行转为灰度图以适配 LeNet-5。这会造成严重的颜色信息断层（如无法通过颜色区分相同材质、不同分类的垃圾）。本实验全量保留了标准的 ImageNet 三通道高质彩色预处理流水线，维持了 RGB 原始特征流。

2、“双端冷启动，中间骨干热加载”微调策略

由于输入由 1 通道演变为 3 通道，且输出由 10 分类变为 26 分类，导致预训练权重的首尾两层与当前任务拓扑不匹配。本实验精妙地修改了网络起始端，将其重构为 `nn.Conv2d(3, 6, 5)`。在加载参数字典（Checkpoint）时，通过条件过滤算法，主动隔离并拒绝加载 `conv1` 与 `fc3` 的固有权重，使其在下游任务中从头接受随机初始化与梯度洗礼；而中间的骨干层（`conv2`、`fc1`、`fc2`）则完美复用预训练参数。

代码实现部分：

数据预处理模块：

```
transform = [
    CV.Decode(),                # 解码图片
    CV.Resize((32, 32)),        # 缩放到 LeNet5 输入尺寸 (32x32)
    CV.Rescale(1.0 / 255.0, 0.0), # 归一化到 [0, 1]
    CV.Normalize(mean=(0.485, 0.456, 0.406), std=(0.229, 0.224, 0.225)), # 3通道标准标准化
    CV.HWC2CHW()                # 转换为 MindSpore 要求的 CHW 格式
]
```

网络拓扑适配模块：

核心改动：将输入通道由 1 改为 3。让第一层卷积承担 RGB 颜色特征融合的任务

```
self.conv1 = nn.Conv2d(3, 6, 5, pad_mode='valid')
```

后续所有经典拓扑层和尺寸完全保持纯正的 LeNet-5 结构

```
self.conv2 = nn.Conv2d(6, 16, 5, pad_mode='valid')
```

```
self.fc1 = nn.Dense(16 * 5 * 5, 120)
```

```
self.fc2 = nn.Dense(120, 84)
```

```
self.fc3 = nn.Dense(84, num_class) # 输出修改为 26 类
```

由于训练的时候出现了梯度爆炸，所以采取了动态梯度的训练方式。


$$\eta(t) = \begin{cases} 0.005, & 1 \leq \text{Epoch} \leq 8 \\ 0.001, & 9 \leq \text{Epoch} \leq 16 \\ 0.0002, & 17 \leq \text{Epoch} \leq 24 \\ 0.00005, & 25 \leq \text{Epoch} \leq 30 \end{cases}$$

第 1 至 8 轮（激进探索期）：利用相对丰满的 $\eta = 0.005$ 学习率，强迫全新的 3 通道 `conv1` 与 26 分类 `fc3` 头快速克服热力学势垒，与热加载的中间骨干网络进行粗粒度知识对齐。

第 9 至 16 轮（梯度下探期）：将学习率收敛至 0.001，此时中间骨干的先验特征流被深度激活，Loss 曲线呈现明显的向下俯冲姿态。

第 17 至 30 轮（收敛降温期）：学习率连续经历两次量级下挫（最低至 0.00005），以极其微弱的局部梯度更新对全连接层的权重进行精细化微雕。

最终训练的结果如下：



本实验在完成 30 个 Epoch（共计 2430 个 Step）的超长周期微调后，将模型部署于完全隔离的测试集进行全量评估，最终核心指标如下：

- 训练样本迭代轮次 (Epochs): 30
- 全量计算步数 (Total Steps): 2430
- 测试集分类准确率 (Top-1 Accuracy): 61.3281%
- 损失函数触底极值 (Min Loss): 0.6376 (于第 26 轮斩获)

实验最终导出了高清图像 `garbage_loss_curve_30epochs.png`。该图表完美呈现了“双线交织”的现代学术级网络监控形态：

- **蓝色发散轨迹（原 Cross Entropy 散点）：**忠实记录了彩色垃圾图像由于背景、光照复杂带来的批次间（Batch-wise）梯度震荡，展现了非凸优化空间中真实的物理扰动。
- **红色平滑趋势线（Smoothed Trend）：**利用 31 阶一维卷积平滑算子对原始轨迹进行包络线提取。趋势线清晰地勾勒出随着四段阶梯式学习率（0.005 $\rightarrow$ 0.001 $\rightarrow$ 0.0002 $\rightarrow$ 0.00005）的逐级斩断，模型 Loss 从初始的 3.30 高位呈现出极其丝滑的台阶式俯冲姿态，在中后期平稳降落并锁死在 0.9 ~ 1.1 之间，无任何滑轨反弹，无任何过拟合翘头。

五、全量微调、冻结微调、Lora 微调

5.1 全量微调 (Full Fine-tuning)

工作原理：将预训练模型（MNIST 权重）加载到新网络后，整个网络的所有核心参数全部解锁，梯度反向传播会计算并更新每一个权重矩阵。

层拓扑细节：

- conv1、conv2（卷积特征提取层）：全面激活。
- fc1、fc2、fc3（全连接层与分类头）：全面激活。

实际作用：使整个网络具备无限的自由度，能够彻底推翻并重塑底层的视觉滤波器，使其完美适应从“黑白简单数字”向“彩色复杂垃圾图像”的跨模态转换。

5.2 冻结微调 (Freeze Fine-tuning)

工作原理：锁死模型前期和中期的核心稠密权重矩阵，将其作为固态的特征

提取器 (Feature Extractor)。由于垃圾分类任务 (26 分类) 与原始手写数字 (10 分类) 存在剧烈的数据偏置平移 (Data Shift)，本实验采用了“冻结核心权重，放开偏置与分类头”的进阶策略，以便网络在极低算力下快速实现数据流对齐。

层拓扑细节：

彻底冻结的参数：conv1、conv2 两个视觉特征提取层，以及 fc1、fc2 的权重矩阵 (Weight)。通过代码 `param.requires_grad = False` 强行拦截其梯度回传。

激活训练的参数：

1. 全新分类头 fc3 的全部参数 (权重与偏置，共 $84 \times 26 + 26 = 2210$ 个)；
2. 浅层至中层的偏置项 (fc1.bias 与 fc2.bias，共 $120 + 84 = 204$ 个)，用于吸收跨域迁移带来的偏置平移。

实际可训练参数量：5,264 个 (仅占全网参数的约 8.3%)。

实际作用：最大化复用原始预训练模型在浅层对几何边缘、简单线条的特征记忆。通过仅仅微调 8.3% 的微量参数，大幅降低计算开销和显存抖动，实现下游新任务的极速轻量级适配。

5.3 LoRA 微调 (Low-Rank Adaptation, 低秩自适应)

工作原理：保持基础模型的原始稠密权重矩阵 (W_0) 完全冻结，在其旁路并联引入由低秩矩阵 A 与 B 构成的增量自适应路径。在训练时，仅更新低秩旁路参数以模拟权重的增量更新 ($\Delta W = B \times A \cdot \frac{\alpha}{r}$)，并在前向传播时将新旧知识线性相加，从而在线性减少可训练参数的同时，保持极强的泛化表达能力。

层拓扑细节：

冻结原有权重：conv1、conv2 彻底锁死。fc1 和 fc2 内部挂载的 `original_dense.weight` 被彻底冻结。

LoRA 嵌入点与秩控制：在网络最吃参数的两大稠密瓶颈层 fc1 和 fc2 上挂载自定义的 LoRADense 旁路。指定低秩超参数 $r = 4$ ，增量信号放大系数 $\alpha = 8$ ，前向传播缩放因子 $scale = 8/4 = 2.0$ 。

激活训练的参数：

- fc1 旁路低秩矩阵：lora_A (形状 400×4) 与 lora_B (形状 4×120)；
fc2 旁路低秩矩阵：lora_A (形状 120×4) 与 lora_B (形状 4×84)；
基础层偏置项：fc1.bias、fc2.bias 以及全新分类头 fc3 的全部参数。

实际可训练参数量：8,160 个 (仅占全网参数的约 12.8%)。

实际作用：利用低秩矩阵的残差学习 (Residual Learning) 机制，在不破坏原模型原有黑白结构稳定性的前提下，利用并联的旁路高效吸纳彩色垃圾分类的高维语义增量，从而展现出远胜于死板冻结微调的结构泛化能力。

5.4 相同超参数下的三种微调结果

为了客观评估全量微调 (Full Fine-Tuning)、冻结微调 (Freeze Fine-Tuning) 与低秩自适应微调 (LoRA) 在相同硬件环境与超参数条件下的真实表现，本实验将三种策略解耦至独立的 Python 进程中串行运行。实验锁死统一的控制变量基准：训练轮次 Epoch = 25，学习率 LR = 0.002，优化器 = Momentum (0.9)。

通过系统级进程资源监视器与框架内置指标进行多维审计，最终横向综合对比结果如下表所示：

微调策略	可训练参数量	总训练耗时	CPU 内存峰值占有 (Peak RSS)	准确率
------	--------	-------	-----------------------	-----

全量微调	63,344	15.73 秒	317.89 MB	72.6562%
冻结微调	5,264	13.88 秒	314.23 MB	23.4375%
lora 微调	8,160	18.69 秒	324.70 MB	31.2500%

本组实验结果呈现出与传统大语言模型（LLM）参数微调中“LoRA 无脑优于全量”截然不同的特征。这恰恰揭示了深度学习计算引擎在超轻量级网络（LeNet5）及剧烈跨领域迁移（Domain Shift）场景下的底层演进机理。

1、内存维度

从数据可见，CPU 物理内存峰值呈现 **LoRA (324.70MB) > 全量 (317.89MB) > 冻结 (314.23MB)** 的逆向趋势。这证伪了“参数量少则内存必然小”的片面结论，其本质原因在于：

全量微调属于原生的单向链式顺序拓扑，在 MindSpore GRAPH_MODE（静态图模式）下编译时计算图极度精简，没有复杂的逻辑分支。

LoRA 微调的本质是在原有的全连接层（Dense）旁额外并联了低秩矩阵 A 和 B。虽然可训练参数大幅减少，但并联分支导致计算图的拓扑复杂度骤增，引入了额外的矩阵乘法、缩放和张量加法等大量底层 C++ 算子节点（Nodes）。

在小模型（仅 6 万参数）中，**LoRA 维护并联拓扑图算子所锁定的静态编译内存，远超其在反向传播中省下的梯度与优化器动量内存**。而冻结微调不仅保持了最精简的单向拓扑，还锁死了 90% 以上的参数，无需开辟梯度缓冲区，因而内存占用在全场表现最低。

2、时序维度

在耗时维度，表现为 **LoRA (18.69s) > 全量 (15.73s) > 冻结 (13.88s)**：

冻结微调由于锁死了大部分网络，反向传播时大量层不需要计算和回传梯度，计算工作量降到极低，因而耗时最短（13.88 秒）。

LoRA 微调耗时最长，是因为其在每一次前向传播中，原本的一步矩阵乘法被重构为了双路径并行计算：


$$Y = W_0X + \frac{\alpha}{r}BAX$$

在 LeNet 这种反向传播本来就极快的浅层网络里，**LoRA 旁路带来的额外前向矩阵乘法计算量以及跨算子调度开销，其时间副作用被成倍放大，反倒拖慢了整体的迭代收敛速度**。

3、精度维度

在准确率维度，呈现 **全量微调 (72.66%) >> LoRA 微调 (31.25%) > 冻结微调 (23.44%)** 的断层式差距。这个的原因有二，其一是原任务与当前的目标任务在特征分布、色彩通道、边缘和空间拓扑等方面存在严重的偏差，所以全量微调是非常必要的，冻结微调和 lora 微调的表达能力有限。

其二是，从 Loss 来看，冻结微调和 Lora 微调的训练并未收敛，如下图所示：



从图中可以看出，Full（全量微调）的 Loss 曲线在后期形成了一个非常漂亮的急剧下滑并最终贴近 0.3 左右的平滑收敛尾部（证明基本收敛）。而 LoRA 和 Freeze 的 Loss 虽然总体也在下降，但在第 25 Epoch 结束时依然剧烈震荡且停留在 2.1~2.4 左右的高位。说明他们并没有达到收敛的位置，需要调高 epoch 或学习率再对比结果。


5.5 超参数调整结果对比

在 5.4 节中，通过对 Loss 曲线的定量分析发现，冻结微调与 LoRA 微调在 25 个 Epoch 结束时斜率依然向下且伴随震荡，表明模型远未达到饱和和收敛状态。为了释放两者的潜在性能，本节打破既定控制变量，实施高强度调优干预：将总训练轮次（Epoch）由 25 轮翻倍至 50 轮，同时将学习率（LR）从 0.002 针对性地提升至 0.01。调优后的单项监测看板数据如下：

冻结微调 (50 Ep / LR=0.01)：耗时 27.34 秒，可训练参数量 5,264，测试集最终准确率：48.0469%

LoRA 微调 (50 Ep / LR=0.01)：耗时 40.27 秒，可训练参数量 8,160，测试集最终准确率：50.0000%

为了直观呈现超参数干预前后的性能演进幅度，绘制对比柱状图如下：



5.5.1 准确率大幅跃迁

调优后，冻结微调的准确率由 23.44% 暴力拉升至 48.05%（实现翻倍）；LoRA 微调也顺利攻破半数大关，由 31.25% 增长至 50.00%。这量化证实了前文的推断：由于 PEFT 策略的可训参数量极小，在低学习率和短周期内梯度积累不足。一旦延长训练周期并加大步长，增量参数得以跨越局部鞍点，泛化表现迎来二次爆发。

5.5.2 时空成本呈现标准线性代价

随着迭代轮次翻倍，两者的耗时（Freeze: 13.88s → 27.34s; LoRA: 18.69s → 40.27s）均呈现完美的线性倍增。这表明耗时的增长完全由前向与反向传播的物理计算量决定，系统并未引发额外的调度死锁。

5.5.3 精度终极天花板的机制判定

值得注意的是，调优后 LoRA (50.00%) 与 Freeze (48.05%) 的差距缩小至不到 2%。这再次印证了跨大领域迁移（MNIST → Garbage）的核心结论：分类性能的绝对天花板由被冻结的浅层卷积层（特征提取器）所锁定。

在调整超参数后，无论是 Freeze 释放偏置项，还是 LoRA 在后端全连接层进行低秩补偿，都已将当前网络在“视觉特征受阻”状态下的潜力榨取到了极限（50% 左右）。若想进一步突破该瓶颈，必须引入对浅层卷积算子的微调。

六、优化模型

6.1 垃圾分类基准模型横向对比

本部分以稍作修改的 LeNet 网络和不引入预训练权重的 MobileNet_v2 网络对比在垃圾分类任务上的特征提取能力和性能表现。

1. 改进方案 A：魔改残差网络 (LeNet5-Residual)

- 设计理念：针对原生 LeNet-5 随着层数加深容易出现梯度消失、难以捕捉复杂彩色图像特征的问题，本方案在保持原有卷积层骨架的基础上，手工嵌入了轻量级残差连接块（Residual Block）并全线引入批归一化层（BatchNorm2d）。
- 拓扑优势：BatchNorm2d 极大稳定了层间特征分布，加速了网络收敛；而残差短路机制（Identity Mapping）为梯度回传提供了一条“低损耗高速公路”，在几乎不增加参数量（仅微增 4.2%）的前提下，大幅压榨了浅层网络的拟合潜力。

2. 改进方案 B：现代轻量化网络 (MobileNetV2 适配版)

- 设计理念：直接引入现代经典的轻量级工业级架构 MobileNetV2，将其全连接分类头修改为适配本任务的 26 分类。
- 拓扑优势：该模型核心采用倒残差结构（Inverted Residuals）与深度可分离卷积（Depthwise Separable Convolution）。它打破了传统卷积“通道-空间”联合计算的模式，将可训练参数量提升至 225.7 万。在不给 GPU 带来灾难性计算负担的前提下，极大地拓宽了特征提取的维度与网络深度，能够敏锐捕捉到垃圾图像的边缘、纹理等高维抽象特征。

为了全面审视拓扑演进（横向）与迭代轮次/优化策略（纵向）对性能的交叉影响，实验共采集了三组全量定量数据：

1、50 Epoch 极限压力测试组（固定学习率）

网络拓扑状态	可训练参数	设置迭代轮	总训练耗	测试集最终准确
--------	-------	-------	------	---------

	量	次	时	率
原生彩色 LeNet	63,344	50 Epoch	37.28 秒	76.5625%
魔改残差 LeNet	66,060	50 Epoch	31.31 秒	80.0781%
MobileNetV2	2,257,178	50 Epoch	188.26 秒	82.8125%
2、30 Epoch 早停性价比测试组（固定学习率）				
网络拓扑状态	可训练参数量	设置迭代轮次	总训练耗时	测试集最终准确率
原生彩色 LeNet	63,344	30 Epoch	37.47 秒	72.6562%
魔改残差 LeNet	66,060	30 Epoch	33.08 秒	75.3906%
MobileNetV2	2,257,178	30 Epoch	104.81 秒	77.7344%
3、30 Epoch 加速控制组（引入动态学习率）				
网络拓扑状态	可训练参数量	设备硬件	总训练耗时	测试集最终准确率
原生彩色 LeNet	63,344	GPU	24.79 秒	40.6250%
魔改残差 LeNet	66,060	GPU	22.26 秒	51.9531%
MobileNetV2	2,257,178	GPU	68.23 秒	80.4688%

1. 横向对比：拓扑结构演进对泛化精度的绝对驱动

纵观三组看板数据，无论在何种迭代轮次或学习率策略下，模型的泛化精度均严格满足：原生 LeNet (Baseline) < 魔改残差 LeNet (Ours-A) < MobileNetV2 (Ours-B)。

- 残差连接的极限性价比：改进后 A（LeNet-Residual）相较于 Baseline，参数量仅增加了约 4.2%（从 63K 到 66K），但在 50 轮测试中，准确率从 **76.56%** 拔高至 **80.08%**。这充分印证了批归一化与残差映射在稳定数据流、提升浅层网络特征表达能力上的学术价值。
- 现代大模型的深层压制：改进后 B（MobileNetV2）由于拥有百万级的参数容量与精妙的倒残差设计，其分类准确率在 50 轮时达到了全场最高的 **82.8125%**，展现出深层视觉模型对于复杂多分类任务的绝对性能压制。

2. 纵向对比：收敛时序与过拟合边界的工程权衡

对比 30 轮与 50 轮（固定 LR）的数据发现，随着训练轮次的追加，三种模型均呈现出泛化精度的单调递增（如 MobileNetV2 从 77.73% 升至 82.81%）。

- 这一发现直接表明：在该垃圾分类数据体量下，**50 轮迭代以内模型并未发生显著的过拟合**，网络仍处于特征吸收期。
- 然而从算力性价比（ROI）审视，MobileNetV2 在后 20 轮迭代中，多付出了 **80% 的算力时间成本**（从 104.81s 飙升至 188.26s），仅换取了 **5.08%** 的边际精度增益。在实际工程落地时，选择 30 轮的“早停配置”无疑是一种在研发效率与精度之间的帕累托最优解。

3. 策略对比：动态学习率在不同体量模型上的“双刃剑”效应

第三组(控制组)引入动态学习率后,实验结果呈现出极具探讨价值的分化现象:

- 深层大模型的完美适配：对于参数量庞大的 MobileNetV2，动态学习率策略大获成功。它不仅将 30 轮的训练耗时**骤降 35%**（由 104.81s 缩短至 68.23s），同时测试集准确率反而**逆势提升了 2.73%**（达到 80.47%）。这说明动态 LR 在训练前期给予的大步长帮助大模型快速冲出鞍点，后期收窄的步长实现了向全局最优解的精准逼近，避免了无效震荡，使 GPU 计算图流转更高效。

- **浅层轻量网络的收敛死锁：**反观原生 LeNet 与残差 LeNet，引入动态学习率后精度出现了断崖式下跌（LeNet 从 72.66% 跌至 40.63%）。其核心原因在于，浅层网络本身的特征提取动能不足，动态策略如果导致学习率衰减过快，会让浅层网络在“尚未充分提取抽象特征”时便过早失去了参数更新的动能，导致模型陷入局部死锁。

4. 反直觉现象分析：数值稳定性反哺 GPU 算力吞吐

在三组实验中，均观察到一个极具学术趣味的反直觉现象：**参数量更大的魔改残差 LeNet (A)**，其总训练耗时无一例外均低于原生 **LeNet (Baseline)**（例如 50 轮时：31.31s < 37.28s）。

在 GPU 算力平台与 MindSpore GRAPH_MODE（静态图模式）下，这完全符合底层计算逻辑：原生 LeNet 缺乏归一化机制，训练中后期极易产生极端数值（过大或过小的异常梯度），这会迫使显卡在浮点数矩阵乘法中触发额外的硬件异常延迟（如反常数 Denormal Number 处理）。而改进组 A 引入 BatchNorm 后，数据分布高度规范，极利于静态图进行**算子融合（Kernel Fusion）**，让英伟达流处理器（SM）执行得更加顺畅，从而达成了“架构更强、参数更多、跑得更快”的帕累托最优。

6.2 跨维度多微调策略消融实验与分析

在深度学习模型的实际部署与训练中，选择合适的微调（Fine-Tuning）策略是平衡硬件算力成本与模型下游任务泛化性能的关键。为了深度评测低秩适应（LoRA）算法、骨干网络冻结（Freeze）算法与全量微调（Full Fine-Tuning, Full-FT）在实际工业算力平台上的表现，本章节依托 NVIDIA Tesla V100 (32GB) 硬件平台，针对 26 类图像垃圾分类任务，精心设计了三组交叉消融控制实验：

1. **50 Epoch 极限压力组：**采用恒定学习率（ $lr = 0.005$ ）进行长周期迭代，观察各策略的极限收敛上限与长期训练稳定性。
2. **30 Epoch 早停性价比组：**采用恒定学习率（ $lr = 0.005$ ）并缩短训练周期，评估在轻量化训练周期下各策略的收敛速度与性价比。
3. **30 Epoch 动态学习率组：**引入 6.1 节演进出的四段式常数退火动态学习率策略（初始 $lr = 0.005$ ，随步数梯次衰减至 0.00005），探究学习率调度器与微调架构之间的深层耦合关系。

6.2.1 交叉消融实验数据看板

三组实验在相同的数据并行流水线与 Batch Size（64）配置下滚动拉起，其核心性能量化指标如下表所示。

实验控制组别	微调策略模式	参与反传参数量	总训练耗时 (秒)	收尾阶段 Loss	测试集最终准确率
50 Epoch 固定学习率	Full-FT	2,291,290	408.5	0.0255	91.41%
	Freeze	33,306	224.1	0.2423	91.02%
	LoRA	38,530	257.8	0.1909	91.80%
30 Epoch 固定学习率	Full-FT	2,291,290	258.3	0.1532	90.62%
	Freeze	33,306	150.8	0.4433	90.23%
	LoRA	38,530	154.3	0.3768	91.41%
30 Epoch 动态学习率	Full-FT	2,291,290	253.2	0.2114	90.62%
	Freeze	33,306	146.0	0.3902	86.72%
	LoRA	38,530	148.4	0.5898	87.11%

6.2.2 核心实验现象与学术深度论述

纵向与横向对比表中的 9 组子实验结果，可以从以下三个学术层面对实验表现进行深度解密：

1. 参数计算效率与显卡吞吐率评估（PEFT 的资源增益）

从可训练参数量和计算时耗维度来看，参数高效微调（PEFT）技术展现出了统治级的硬件剪裁能力。全量微调（Full-FT）由于需要对整个 MobileNetV2 网络的 **2,291,290** 个参数全部进行梯度计算与反向传播，其在 50 Epoch 下的总耗时达到了 408.5 秒。

相比之下，Freeze 策略与 LoRA 策略通过锁死主干网络的参数，将参与反传的可训练参数量分别急剧压缩至 **33,306**（仅占全量的 1.45%）与 **38,530**（仅占全量的 1.68%）。这种低参数量更新在 V100 显卡上直接转化为可观的训练吞吐增益：在 50 Epoch 条件下，Freeze 和 LoRA 的训练时耗分别锐减至 224.1 秒与 257.8 秒，**整体算力开销和时间成本节省了约 36.9% ~ 45.1%**。这强力论证了在工业级算力受限或敏捷开发场景下，采用轻量化微调技术以降低硬件负载的极高现实价值。

2. 长周期迭代下的泛化保护机制（LoRA 的精度逆袭）

在传统的深度学习认知中，减少可训练参数往往伴随着拟合能力下降的风险。然而，在“50 Epoch 极限压力组”与“30 Epoch 早停性价比组”中，**LoRA 策略连续斩获了全场最高的分类准确率（分别为 91.80% 与 91.41%）**，甚至超越了全量微调（Full-FT）。

本文分析认为，这一反直觉的优异表现源于 **LoRA 的泛化保护机制**。预训练模型 MobileNetV2 在大型通用数据集上已经构建了极其扎实且通用的底层视觉特征空间（如边缘、纹理等特征流形）。全量微调由于强制破坏了原本稳定的通用权重，在样本规模有限的 26 类下游垃圾分类数据集中，极易使主干网络陷入过拟合（Overfitting）的陷阱。

而 LoRA 算法通过引入低秩旁路矩阵 $\Delta W = B \times A$ ，在完美保护通用主干网络不被破坏的同时，显式且高效地拟合了下游任务的独特特征。这种设计兼顾了“上游大模型泛化性”与“下游任务精准对齐”，从而在测试集上表现出了比全量微调更好的鲁棒性与精度。

3. 学习率退火异常现象分析

在本章节交叉消融实验中，最具研究价值的学术现象出现在“30 Epoch 动态学习率组”。在引入了 6.1 节设计的四段式常数退火机制后，全量微调（Full-FT）保持了 90.62% 的高精度平稳过度；然而，Freeze 策略与 LoRA 策略的测试集准确率却骤然分别下跌了 3.51% 和 4.30%（LoRA 由 91.41% 跌至 87.11%），且收尾 Loss 明显偏高。

针对这一明显的“性能倒退”冲突，本文提出了以下微观机制解释：

梯度分摊机制差异：在全量微调（Full-FT）中，整个网络全部参与优化，0.005 的高初始学习率被 229 万个参数分摊，梯度更新平滑。然而，LoRA 和 Freeze 模式下，被更新的参数空间高度浓缩（不足 4 万参数），在训练初期注入 0.005 的大步长，极易在极小参数空间内引发局部的梯度振荡，将新初始化分类头的敏感结构“暴力踢飞”。


短周期下的优化器锁定：由于垃圾分类任务单轮迭代的 Step 步数较少（每轮 40 Step），在前 8 个 Epoch 发生严重的梯度震荡并偏离最优路径后，优化器还未等特征空间完成二次自适应修复，学习率就在第 9 轮和 17 轮迅速步入极小值（0.0002 和 0.00005）。这导致轻量化微调参数在后半程缺乏足够的能量跨

越局部的“势垒”，最终被锁死在次优的局部极小值点（Local Minima）中，无法精细降落。

6.3 基础拓扑演进与参数高效微调（PEFT）改进策略的综合对比

为了全面评估从轻量化网络拓扑设计到高性能大模型参数高效微调（PEFT）的技术演进红利，本小节将 6.1 节中从头训练的模型（原生彩色 LeNet、魔改残差 LeNet、MobileNetV2 从头训练组）与 6.2 节中基于预训练权重的改进微调模型（MobileNetV2 Full-FT、Freeze、LoRA）进行多维度的宏观综合对比。

图 6-3 完整展示了各改进模型在三种核心实验条件（50 Epoch 固定学习率、30 Epoch 固定学习率、30 Epoch 动态学习率组）下的测试集最终准确率与总训练耗时表现。



6.3.1 准确率维度的飞跃：预训练表征的降维打击

分析图 6-3(a) 可以清晰地看出，基于预训练权重的微调改进模型（Full-FT、Freeze、LoRA）在准确率维度上对从头训练路线实现了全面的阶跃式突破：

长周期极限收敛上限：在 50 Epoch 极限组中，从头训练的最高精度仅为 MobileNetV2 的 82.81% 与魔改残差 LeNet 的 80.08%。而引入微调改进策略后，LoRA 改进模型以 **91.80%** 的全场最高精度傲视群雄，较之拓扑结构完全相同的从头训练 MobileNetV2，**绝对精度净增 8.99%**。这强力论证了上游大规模预训练所沉淀的通用特征流形，在小样本下游垃圾分类任务中具备压倒性的泛化优势。

对动态学习率的抗噪表现：在 30 Epoch 动态学习率控制组中，从头训练路线因初始步长过大导致轻量化网络（如原生 LeNet）直接崩溃，精度跌至 40.63%。相比之下，微调策略组表现出了极强的鲁棒性，Full-FT 依然死死锚定在 90.62% 的高位，而经过 LoRA 优化后的改进模型也能平稳收敛于 87.11%。这表明改进的微调策略不仅提升了上限，更极大增强了模型在复杂训练调度下的稳定性。

6.3.2 算力性价比震荡：训练时耗与精度的帕累托优化

对比图 6-3(b) 的计算运行时耗，可以深入揭示不同改进策略在硬件资源消耗上的博弈平衡：

极端算力开销的跨越：全量微调（Full-FT）虽然精度高，但由于 229 万参数全部参与反向传播，50 Epoch 下的时耗高达 **408.5 秒**，比从头训练的 MobileNetV2（188.3 秒）高出两倍有余。

LoRA 改进策略的帕累托最优（Pareto Optimality）：高效微调改进策略

(LoRA) 的引入彻底打破了精度与时耗的线性绑定。LoRA 通过冻结主干网络并引入低秩旁路，将大模型微调的时耗急剧压缩至 **257.8 秒**（相比 Full-FT 缩短了 **36.9%**）。

尽管这一时耗依然高于极端轻量化的从头训练 LeNet (31.3 秒)，但它以**极其有限的算力溢价**（仅多出约 **220 秒**），换取了超过 **11% 到 15%** 的**决定性精度增益**。这种“低开销、高回报”的改进行为，在计算图谱上成功构建了一条完美的性价比帕累托前沿线。

6.3.3 本章小结

纵观整章两阶段消融与改进实验，垃圾分类模型的优化路径形成了清晰的递进闭环。从最初的基础 **Baseline**（原生 **LeNet: 76.56% 精度**）出发，首先通过**拓扑演进**（魔改残差 LeNet 提升至 80.08%，更换 MobileNetV2 骨干提升至 82.81%）夯实了特征提取基础；随后通过引入**高级微调策略**进行二次改进，最终凭借 **MobileNetV2 + LoRA 策略**在 NVIDIA V100 平台上以 257.8 秒的敏捷训练算力，斩获了 **91.80%** 的极致泛化准确率。

七、实验总结

本实验在 MindSpore 框架下，成功复现了经典的 LeNet5 手写数字识别流程，深入剖析了其卷积、下采样及特征图尺寸演进的底层算子逻辑与算法流程。以此为基石，实验针对多通道、高维度的现代垃圾分类任务重构了数据预处理管线与网络首尾拓扑层，实现了由 MNIST 灰度域到彩色生活场景域的跨任务冷启动与热加载迁移。在模型微调与优化阶段，通过设计全量微调（Full-FT）、冻结微调（Freeze）及低秩适应微调（LoRA）的消融对照实验，从可训练参数量、硬件显存/内存消耗、时间开销及模型精确度四大物理维度展开定量分析，深刻揭示了 PEFT 旁路结构在小模型应用中带来的静态图计算图谱复杂度溢出，与在大模型应用中带来的极限泛化红利。最终，通过引入轻量化残差 BatchNorm 改良结构与具有倒残差及深度可分离卷积的 MobileNetV2 尖端网络进行超参控制变量改进，将测试集最终准确率一举从 76.56% 拉升至 91.80% 的阶跃式突破。整个实验完美闭环了“开源复现—跨域迁移—全维消融—网络改良”的全流程，不仅深度验证了深度学习骨干网络的高级表征泛化能力，更为在受限硬件算力平台下部署面向实际垂直领域的轻量化、高精度智能图像识别系统沉淀了坚实的技术方案与实践经验。