

同濟大學

TONGJI UNIVERSITY

课程设计作业 4

课题名称 大模型：古诗转水墨画实验报告

学 院 计算机科学与技术学院

专 业 计算机科学与技术

学生姓名 黄宇镐

学 号 2452536

日 期 2026 年 5 月 27 日

目 录

1 实验背景与实验内容	1
1.1 实验背景	1
1.2 实验内容	1
2 Stable Diffusion v1.5 模型部署与文生图流原理解析	2
2.1 实验环境配置	2
2.2 核心组件工作原理	2
2.2.1 VAE (变分自编码器)	2
2.2.2 CLIP Text Encoder (文本编码器)	2
2.2.3 UNet (去噪残差网络)	2
2.2.4 Scheduler (采样调度器)	3
2.3 算法流程	3
2.4 实例	3
3 异构数据集构建与全量参数微调	4
3.1 异构数据集构建与图像预处理机制	4
3.1.1 JPG-CSV 异构数据对齐组织	4
3.2.2 潜空间感知域预处理管道	4
3.2 UNet 全量参数微调架构设计	4
3.2.1 全量机制激活与组件冻结	4
3.2.2 优化器、物理损失函数与反向传播闭环	4
3.3 实际生成效果分析与改进方向指出	5
3.3.1 实际生成效果定性评估	5
3.3.2 底层硬件监控指标揭示的工程局限	5
3.4 风格化微调前后视觉收敛效果对比	6
3.4.1 古诗写意水墨画微调组	6
3.4.2 3D 粘土材质艺术微调组	7
4 推理超参数消融实验与生成策略演进	8
4.1 推理超参数多维矩阵消融实验设计	8
4.1.1 消融实验搜索空间配置	8
4.2.2 实验严谨性控制（固定伪随机种子）	8
4.2 消融矩阵结果定性与定量分析	8
4.2.1 采样步数的收敛演进	9
4.2.2 指导系数的意境与笔触强刷	9
4.3.3 最终工程结论与黄金参数组合锚定	10
5 局部 Cross-Attention 提取与 LoRA 轻量化机制	11
5.1 Dreambooth 与 LoRA 轻量化微调数学原理	11
5.1.1 Dreambooth 先验知识保持机制	11
5.1.2 LoRA 低秩自适应增量矩阵公式	11
5.2 局部 Cross-Attention（交叉注意力）精准提取靶向策略	11
5.2.1 靶向挂载网络层名称	11
5.2.2 局部 Cross-Attention 靶向微调的物理学机理	12
5.3 LoRA 风格强度因子（Scale）响应分析与最优值选取	12
5.4 视觉效果定性分析	13
5.4.1 写意水墨风格定性分析：形体保持与意境晕染的博弈	14
5.4.2 3D 粘土风格定性分析：逆向材质重构与形体崩溃	15

5.5 实验结果量化分析	15
5.5.1 动态峰值显存分析	16
5.5.2 时间耗时分析	16
5.5.3 模型体积分析	16
6 跨文化文本语义表征瓶颈与前置重构优化	17
6.1 CLIP 文本编码器的“文化失语症”机理分析	17
6.2 基于大语言模型（LLM）的前置提示词解耦重构	17
6.3 双案例提示词消融实验结果定性分析	18
6.3.1 案例一《江雪》语义流变定性解构	18
6.3.2 案例二《早发白帝城》语义流变定性解构	19
6.4 物理替换文本编码器（Chinese-CLIP / AltDiffusion）的可行性论证	19
6.4.1 数学层面的特征对接（Dimension Matching）	19
6.4.2 中文艺术先验的物理激活	19
6.5 工程折衷（Trade-off）与技术决断	20
7 总结	21

装

订

线

1 实验背景与实验内容

1.1 实验背景

本次实验背景立足于中华优秀传统文化的数字化传承，将具有“意境营造”与“写意表达”高度契合的古诗与水墨画相结合，利用以深度学习为核心的生成式 AI，如开源的 Stable Diffusion v1.5 文本到图像生成模型，以及 Python 和 PyTorch 深度学习框架，将抽象的古诗语言转化为具象的水墨画视觉画面，旨在通过文生图与模型微调等技术实践，让学习者深入理解可控生成式大模型的底层逻辑与关键技术，实现“以诗绘景、以景传情”的艺术可视化。

1.2 实验内容

本次实验的核心内容围绕“古诗转水墨画”这一跨模态生成任务展开，系统性地完成了从基础模型部署到高级微调与推理优化的全链路技术实践。具体包括以下几个方面：

- 模型部署与文生图流程实现：**基于 Python 与 PyTorch 框架，在 AutoDL 云端环境中完成 Stable Diffusion v1.5 的离线化部署，组织 VAE、CLIP 文本编码器、UNet 与 Scheduler 五大核心模块，并实现完整的文本到图像生成流水线。
- 异构数据集构建与全量参数微调：**构建“水墨写意”与“3D 粘土材质”两类小样本图文对数据集（每组 5 张图像），分别对 UNet 进行全量参数微调。分析其风格迁移能力与“灾难性遗忘”问题，并指出显存占用高、模型体积大等工程局限。
- 推理超参数消融实验：**设计 CFG 引导系数与采样步数的 3×3 网格搜索实验，固定随机种子，系统分析二者对生成图像意境、细节收敛与画面稳定性的影响，并确定最优推理参数组合（CFG=7.0, Steps=35）。
- LoRA 轻量化微调与局部 Cross-Attention 靶向优化：**引入 Dreambooth + LoRA 架构，冻结 UNet 主干网络，仅对 Cross-Attention 模块（Q、K、V、Out 投影层）挂载低秩增量矩阵。通过风格强度因子消融实验确定最优权重（S=0.3），在显著降低显存与模型体积的同时，保留空间几何结构并实现高质量风格迁移。
- 文本编码器跨文化瓶颈分析与优化：**揭示 CLIP 文本编码器在面对中国古典诗词时的“文化失语症”，提出基于大语言模型（LLM）的前置提示词重构方案，将古诗词意象解耦为“主体—环境—材质—意境”四维提示词，显著提升生成图像的文化适配性与东方美学表现力。

通过上述实验内容，本文系统探索了从模型部署、全量微调、轻量化适配到跨文化语义对齐的完整技术路径，为生成式 AI 在传统文化数字化传承中的应用提供了可复现、可工程化的实践范式。

2 Stable Diffusion v1.5 模型部署与文生图流原理解析

2.1 实验环境配置

本实验基于 PyTorch 深度学习框架，在 AutoDL 算力云端环境完成了 Stable Diffusion v1.5 的本地化部署。为保障微调及推理的高效进行，系统底层搭建在 NVIDIA 算力芯片上，并配置了完备的 CUDA 推理加速驱动。

由于在线加载权重易受网络震荡、握手延迟等不确定因素影响，本实验采取了**全组件离线预载策略**。在 /root/autodl-tmp/sd_v15 目录下，严格按照 Hugging Face diffusers 库的工程规范，完整部署并组织了以下五个核心子模块：

/tokenizer：负责将离散的提示词切分为分词序列。

/text_encoder：负责将文本分词流映射为高维连续文本语义向量。

/unet：潜空间噪声预测核心主干网络。

/vae：负责像素空间与低维隐空间双向转换的变分自编码器。

/scheduler：噪声步长控制与去噪轨迹调度器。

2.2 核心组件工作原理

Stable Diffusion v1.5 的核心技术突破在于将传统扩散模型的迭代计算从高维的像素空间（Pixel Space）**转移到了低维的潜空间（Latent Space）**中进行，在大幅消减计算资源消耗的同时，完美保留了生成图像的细节纹理。其协同作业由以下四大核心组件共同闭环完成。

2.2.1 VAE (变分自编码器)

VAE 在生成流水线中充当像素世界与隐空间世界的“空间转译网关”。

编码端 (Encoder)：将输入的高维 RGB 图像（尺寸为 $3 \times 512 \times 512$ ）压缩为低维潜空间特征图（Latents，尺寸为 $4 \times 64 \times 64$ ），数据体积在空间维度上被压缩了 64 倍。

潜空间缩放控制：为使压缩后的潜空间数据具备标准正态平稳性，便于 UNet 网络精准捕捉噪声残差，引入了特定的数学缩放系数 0.18215。所有特征在进入隐空间前必须遵循如下映射：

$$z = \text{Encoder}(x) \times 0.18215$$

解码端 (Decoder)：在反向去噪链路完成后，Decoder 接收纯净的低维潜在特征，执行逆向放大与升维，最终复原为人类可读的高清像素图像。

2.2.2 CLIP Text Encoder (文本编码器)

文本编码器是跨模态语义引导的“导航仪”，本实验采用 OpenAI 开源的 CLIP (ViT-L/14) 架构。

序列截断与补齐 (Tokenization)：输入的古诗词或风格提示词首先通过 Tokenizer 被切分为离散的词片 (Tokens)，并统一对齐 (补齐或截断) 至模型底层所限制的最大文本长度 77。

连续语义表征 (Embedding)：Text Encoder 将这 77 个词片索引映射为一个尺寸为 77×768 维的高维连续文本特征矩阵 (Text Embeddings)。该矩阵深度凝聚了文本的内在逻辑，作为条件 (Conditioning) 输入强行注入 UNet 中。

2.2.3 UNet (去噪残差网络)

UNet 是 Stable Diffusion 内部参数量最大、最核心的非线性特征提取网络，其本质是一个**噪声预测器**。

拓扑架构：采用标准的“编码器-中介块-解码器 (Encoder-Middle-Decoder)”多尺度下采样与上采样对称网络，内部由 ResNet Block (残差块) 与 Transformer Block (注意力块) 复合而成。

交叉注意力 (Cross-Attention) 机制：这是实现文生图跨模态融合的关键桥梁。潜空间图像特征 F_{img} 经由线性投影派生出查询向量 Q ，文本特征 F_{text} 派生出键向量 K 和值向量 V 。系统通过计算图像与文本在隐空间中的关联矩阵，强行控制噪声的演化方向去对齐古诗词的语义意境：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V$$

2.2.4 Scheduler (采样调度器)

Scheduler 是控制时间步加去噪行为的数学调度账本（本实验采用经典的 **DDPM** 调度器）。它不包含可训练的权重参数，而是基于预设的方差序列（ β_t ）严格定义了前向扩散的加噪规律。在反向推理去噪时，它根据当前所处的时间步 t ，将 UNet 预测出来的噪声残差从当前的模糊特征图中精准扣除，并控制回退的步长与方差扰动，引导潜在变量平稳收敛。

2.3 算法流程

触发序列	对应组件名称	输入模态及维度 (Tensor Shape)	输出模态及维度 (Tensor Shape)	物理/数学意义说明
步骤 1	Tokenizer	原始自然语言字符串 (str)	离散词片索引流 [1, 77]	将人类语言切分为离散数字序列
步骤 2	Text Encoder	离散词片索引流 [1, 77]	连续语义矩阵 [1, 77, 768]	将文本锚定至跨模态连续语义坐标系
步骤 3	Gaussian Init	无（物理发生器）	隐空间纯噪声 [1, 4, 64, 64]	构建反向扩散的初始混沌状态
步骤 4	UNet 主干	隐变量 [1, 4, 64, 64] + 文本引导	噪声残差预测 [1, 4, 64, 64]	通过交叉注意力，计算图文跨模态相关性
步骤 5	Scheduler	噪声残差 [1, 4, 64, 64]	纯净化隐变量 [1, 4, 64, 64]	逆马尔可夫链步进，逐步剥离熵增噪声
步骤 6	VAE Decoder	纯净潜在特征 [1, 4, 64, 64]	高清 RGB 图像 [1, 3, 512, 512]	跨越隐空间闸门，升维放大为具象艺术画

2.4 实例

在模型部署之后，做了一个基本的测试，生成图片的提示词为"A traditional Chinese ink wash painting, mountains and rivers shrouded in mist, high quality, masterpiece"。生成的图片为如下：




图 2-1 模型基底测试

3 异构数据集构建与全量参数微调

3.1 异构数据集构建与图像预处理机制

在深度学习微调任务中，高质、规整的数据流是模型收敛的前提。本实验针对“传统水墨写意”与“3D 粘土材质”两种截然不同的视觉风格，分别构建了小样本数据集（每组包含 5 张核心表征图像），以测试模型在强能量聚焦下的过拟合风格迁移能力。

3.1.1. JPG-CSV 异构数据对齐组织

数据集采用工业界标准的图文对（Image-Caption Pairs）结构进行组织。本地存储架构包含一个 images/ 文件夹（存放高质 JPG 视觉样本）和一个 metadata.csv 索引文件。通过 Python 的 Pandas 库，系统建立起“文件名 → 提示词标签”的异构映射账本。在数据加载阶段，自主编写的 PyTorch Dataset 子类将通过索引检索指定行的图片，并同时绑定其专属的文本触发词（Prompt），实现跨模态图文数据流的同步批处理（Batching）。

3.2.2. 潜空间感知域预处理管道

为了使输入的像素图像完全契合 Stable Diffusion v1.5 的固有认知结构，必须通过 torchvision.transforms 算子链对原始图像进行严格的数学剪裁与空间归一化。图像预处理流的核心步骤如下：

- 等比例缩放与中心裁剪（Resize & CenterCrop）：

原始图像分辨率各异，直接拉伸会导致画面形体扭曲。系统首先通过双线性插值（Bilinear Interpolation）将图像短边缩放至 512 像素，随后执行中心裁剪，锁定 512 × 512 像素的正方形核心区域。

- 张量化与数值域归一化（ToTensor & Normalize）：

通过 ToTensor() 将 PIL 图像矩阵转化为阶数为 3 的 PyTorch 张量，此时像素数值域从 [0,255] 线性映射至 [0.0,1.0]。

由于变分自编码器（VAE）在预训练时的隐空间感知域分布在 [-1.0,1.0] 之间，因此必须通过下述中心化公式实施通道像素重构：

$$x_{\text{norm}} = \frac{x_{\text{tensor}} - 0.5}{0.5}$$

经过此管道处理后，图像数据方可注入 VAE 的编码端。

3.2 UNet 全量参数微调架构设计

全量参数微调（Full Fine-Tuning）是建立基线（Baseline）效果的核心技术路线。其本质是解除预训练大模型的一切前向传播锁死限制，允许反向传播梯度对主干网络进行无死角的权重刷新。

3.2.1. 全量机制激活与组件冻结

在微调启动阶段，为了将算力集中于视觉特征的重构上，并规避文本理解能力的退化，本实验对 Stable Diffusion v1.5 的内部组件实施了选择性解冻策略：

彻底冻结 (Requires_Grad = False)：变分自编码器（VAE）与文本编码器（CLIP Text Encoder）。在训练全过程中，它们仅执行前向传播以提取隐变量与文本嵌入，其内部神经元权重不产生任何梯度。

完全激活 (Requires_Grad = True)：去噪主干网络（UNet）。通过显式调用 unet.requires_grad_(True)，解冻 UNet 神经网络内部包含的所有卷积层、残差块（ResNet Blocks）以及自注意力/交叉注意力层（Transformer Blocks），使其几十亿规模的参数矩阵处于可刷新状态。

3.2.2. 优化器、物理损失函数与反向传播闭环

全量微调的底层数学闭环基于噪声残差的均方误差（MSE）最小化。

噪声注入与隐空间前向传播:

VAE 提取的纯净隐变量 z_0 在乘以潜空间缩放系数 0.18215 后,系统随机生成一个相同维度的标准高斯噪声 $\epsilon \sim N(0, I)$ 。根据预设的时间步 t ,调度器 (Scheduler) 将噪声融合进隐变量中,构建出模糊状态 z_t 。

损失函数 (Loss Function) 定义:

UNet 接收模糊隐变量 z_t 、时间步 t 与文本条件 C ,输出预测噪声 ϵ_θ 实验采用像素级 MSE Loss 作为目标函数:

$$L_{MSE} = E_{z, \epsilon, t, C} [\|\epsilon - \epsilon_\theta(z_t, t, C)\|_2^2]$$

优化器配置与反向传播:

系统配置 AdamW 优化器 (一阶动量系数 $\beta_1 = 0.9$, 二阶动量系数 $\beta_2 = 0.999$)。在每个 Step 结束时,通过 `loss.backward()` 计算全局梯度,优化器根据动量定理刷新 UNet 全量参数,强行重塑神经网络对目标风格在隐空间内的条件概率分布分布。

3.3 实际生成效果分析与改进方向指出

在通过 AutoDL 算力平台跑通水墨风格 (任务 2, 迭代 10 轮) 与粘土风格 (任务 3, 迭代 15 轮) 的全量微调后,导出了完整的 3.20 GB 独立 UNet 权重文件。通过对微调模型的生图测试进行定量与定性评估,本实验客观指出了全量参数微调策略在工程与业务落地上的严重局限性。

3.3.1 实际生成效果定性评估

生成效果优势

全量参数微调可实现显著的风格迁移效果,模型对目标视觉特征具有较强的拟合能力。经微调后,水墨画风格模型可生成具有典型写意特征的画面,呈现出均匀的墨色晕染、自然的飞白笔触与朦胧氤氲的水汽质感;3D 粘土风格模型可赋予对象厚重的泥塑体积感,边缘过渡柔和,并呈现出橡皮泥特有的表面光泽与捏合痕迹,风格辨识度较高。

灾难性遗忘与几何结构畸变

全量微调通过解冻 UNet 全部参数实现全局更新,在小样本训练条件下易引发严重过拟合,进而产生灾难性遗忘现象。模型虽可记忆训练集中的色彩分布与材质特征,但显著丢失预训练模型所具备的通用视觉先验,包括现实物理规则、空间几何结构、透视关系与构图合理性。在“古诗转水墨画”生成任务中,模型频繁出现几何结构错乱、主体形态畸变、前景与背景逻辑冲突等问题,画面物理一致性与空间合理性难以保障。

3.3.2 底层硬件监控指标揭示的工程局限

全量微调虽可实现高强度风格迁移效果,但会对底层系统资源造成极大负载,相关硬件监测数据如下:初始静态显存占用:4.00 GB (模型权重加载至显存后的常驻物理内存占用),训练动态峰值显存:16.92 GB (反向传播阶段,全局数十亿参数对应的梯度矩阵缓存所致),模型导出物理体积:3.20 GB (完整 UNet 网络参数全量导出文件大小)。

1 显存资源占用过高,硬件门槛显著提升

本实验将批次大小 (Batch Size) 设置为 1,采用最轻量训练配置,模型反向传播过程中产生的梯度矩阵,仍使训练阶段峰值显存占用达到 16.92 GB。由此可见,全量微调方案无法在 12GB 及以下显存的主流消费级显卡中完成训练,硬件适配范围受到严格限制。

2 模型体积偏大,引发存储、传输与部署瓶颈

全量微调会更新 UNet 网络全部参数,最终生成的模型文件体积达 3.20 GB。在工业高并发生产场景下,若需面向多类业务需求定制古风、动漫、写实等差异化风格模型,服务端需频繁完成数 GB 级模型文件的网络传输、显存加载与切换操作,极易造成服务响应延迟,同时形成瞬时网络带宽拥堵,难以满足规模化部署要求。

3 技术优化演进方向

针对上述工程缺陷,本研究确定三项后续优化与技术迭代路线:

- 引入参数高效微调 (PEFT/LoRA) 方案:保留模型 99% 的基础网络参数与结构,仅在

模态交互层引入低秩增量矩阵，摒弃全参数更新模式。从底层降低显存占用、缩减模型体积，同时保留模型原有通用语义能力。

- 采用非对称超参数配置策略：针对不同风格特征设置差异化训练轮次（Epoch），抑制因过拟合引发的画面失真、人物形态畸变等问题。
- 切换 SDXL 高维语义基底模型：升级双向文本编码模块，弥补原有基础模型对东方古典诗词语义、意境理解不足的缺陷，消解文化表达断层问题。

3.4 风格化微调前后视觉收敛效果对比

本节展示了本研究在任务（2）与任务（3）中所实现的全量参数微调可视化结果。实验统一采用 2×2 矩阵网格进行横向拓扑对比，以客观评估基底底模（Base Model）与全量微调模型（Full Fine-Tuned）在隐空间特征捕获上的实质差异。

3.4.1 古诗写意水墨画微调组

在水墨画风格演进实验中，图 3-1 展现了明显的跨模态特征洗脑痕迹：

- **舟船意象（a vs b）**：原生底模（a）生成的画面线条僵硬，山峦呈现出西方素描的网格排线质感；经微调后的模型（b）展现了纯正的传统中国画写意技法，远景山脉转化为大面积的墨迹晕染与水汽留白，近景松柏与波纹具备了毛笔走线的飞白笔触。
- **奔马意象（c vs d）**：全量微调（d）在延续（c）动态骨架的同时，极大增强了水墨粗线条的黑白对比度，马匹躯干处的墨迹呈现出宣纸特有的非线性晕染扩散效果，成功在小样本下实现了局部概率分布的重塑。



图 3-1 水墨画风格测试图

3.4.2 3D 粘土材质艺术微调组

在 3D 粘土风格演进实验中，图 3-2 揭示了模型对物理世界材质认知的重写：

- **钢铁侠意象 (a vs b)：**原生底模 (a) 表现为现代写实 CGI 渲染的硬质塑料或金属烤漆质感；微调模型 (b) 则为机械躯壳强行覆盖了一层“厚泥塑”的圆润捏痕，背景边缘被软化，呈现出黏土动画 (Claymation) 特有的高内聚光泽。
- **耳廓狐意象 (c vs d)：**微调后的小狐狸 (d) 毛发质感完全褪去，转而呈现出块面化、微有手作瑕疵的软橡胶橡皮泥体块，背景也由单调的皮质纹理坍塌并过拟合为具有粘土颗粒感的泥质户外微缩景观。




图 3-2 粘土风格测试图

4 推理超参数消融实验与生成策略演进

4.1 推理超参数多维矩阵消融实验设计

在任务（4）的定性分析中可以发现，全量微调极易导致模型陷入局部最优或过拟合。为了定量和定性地分析模型在推理阶段对核心控制参数的敏感度，避免盲目调参，本实验基于自主编写的 `test_param_optimization.py` 脚本，构建了一个 3×3 的双轴网格搜索（Grid Search）消融矩阵。

4.1.1 消融实验搜索空间配置

本实验锁定了决定扩散模型生成质量的两大核心推理超参数，并为其配置了梯度搜索空间：

- **纵轴：无分类器指导缩放系数（CFG Scale / Guidance Scale）** CFG 控制提示词对画面的强刷控制力度。实验设定搜索空间为 $[4.5, 7.0, 9.5]$ 。
 - 4.5（低引导）：给予模型隐空间更多的自由发挥度；
 - 7.0（标准引导）：工业界文生图的标准平衡点；
 - 9.5（高强度强刷）：强行让 UNet 的每一步反向扩散去严格贴合文本。
- **横轴：反向采样步数（Inference Steps）** 采样步数决定反向马尔可夫链的离散迭代频次。实验设定搜索空间为 $[20, 35, 50]$ 。
 - 20（低步数欠采样）：测试调度器在极限低频下的收敛效率；
 - 35（标准采样）：兼顾生成速度与画面完整度的平衡配置；
 - 50（高步数精细采样）：探索模型在隐空间中的画质表现极限。

4.2.2 实验严谨性控制（固定伪随机种子）

为了保证消融实验的绝对公平，排除由于潜空间初始高斯白噪声分布不同对画面带来的干扰，代码在每场渲染前通过 `torch.Generator(device="cuda").manual_seed(1024)` 强制将随机数种子死锁在 1024。这确保了 9 次渲染的初始“混沌状态”完全一致，画面的一切物理异动和材质演变完全由 CFG 和 Steps 的参数变更引起。

4.2 消融矩阵结果定性与定量分析

本实验统一采用更新后的提示词 *“a traditional Chinese ink painting of a single small boat on a quiet river, misty mountains background, ink wash, ancient poem landscape”* 进行测试。




图 4-1 超参数多维矩阵图

运行参数优化脚本后，系统自动导出了 3×3 的超参数网格搜索矩阵图 4-1。由于在每场渲染前死锁了潜空间随机种子，画面中的远山、近树、孤舟的“骨架坐标”保持了高度的物理对照性。基于此，本实验对推理超参数的协同控制机理进行深度的图像学定性剖析：

4.2.1 采样步数的收敛演进

横向观察网格可以发现，采样步数直接控制了隐空间调度器 (Scheduler) 对噪声流的剥离精细度：

- **低步数欠采样 (S:20)：**在任意 CFG 梯度下，20 步的画面已完成了宏观构图，但细节处存在明显的“收敛不全”。例如，中景树木的枝叶略显黏连，远山皴法（中国画画山石的手法）的线条边界有轻微的高频微小噪声伪影。
- **标准与精细采样 (S:35 $\rightarrow$ S:50)：**随着迭代步数的拉长，反向马尔可夫链的去噪步长更加确定。可以清晰地观察到，左下角近景处的小舟轮廓从模糊变得锐利、坚实；中景处的房屋建筑结构更加错落有致；特别是远山与迷雾的过渡 (Misty background)，在 50 步时展现出了极为细腻的非线性灰色渐变，水墨洗练 (Ink wash) 的层次感被完全释放。

4.2.2 指导系数的意境与笔触强刷

纵向观察网格能够最直观地体现模型对提示词中“传统（traditional）”与“水墨（ink wash）”语义的顺从度与物理方差变化：

- **弱引导区间（CFG:4.5）**：整体画面色调偏向淡雅、柔和。远山呈现出朦胧的灰色半透明质感，非常符合“静谧（quiet river）”与“迷雾（misty）”的古诗写意意境。然而，由于引导强度不足，画面最右侧的落款红印、右上角的山体边缘出现了一定程度的语义逸出，国画的焦墨重色未被充分激活。
- **标准平衡点（CFG:7.0）**：画面达到了完美的艺术平衡。山峦的线条开始用重墨进行勾勒（类似于传统国画中的“勾”技法），黑白对比度（Contrast）显著提升。近景树木的枝干具有了毛笔走线的刚劲感，落款红印的色泽也更加饱和。
- **强引导与饱和过拟合（CFG:9.5）**：当引导系数拉满到 9.5 时，UNet 网络为了无限迎合“传统水墨画（traditional Chinese ink painting）”的条件概率分布，开始对画面进行**饱和式重度轰炸**。山体的勾勒线条变得极度粗暴、厚重，原本淡雅的写意山水被迫转型为“焦墨/泼墨”风格。特别是在 [CFG:9.5, S:20] 组合中，由于步数少且强刷力度大，山脊顶部甚至出现了由于方差崩溃引发的**黑色斑块（Over-saturation，俗称画面烧焦）**，破坏了古诗词中“静谧与迷雾”本该拥有的留白（Negative space）神韵。

4.3.3 最终工程结论与黄金参数组合锚定

通过对 3×3 消融矩阵的纵横联合评估，本实验得出以下超参数调优的底层系统性结论：**CFG 决定风格的张力与纯度，Steps 决定细节的收敛与纯净**。针对古诗词风景这种强调“气韵生动、虚实相生”的特定任务，过高的 CFG（如 9.5）会导致画面结构过载与烧焦；而过低的 Steps（如 20）则会导致画面细节毛糙。综合生图质量与系统计算耗时，本研究最终确定了该模型的**最佳推理超参数组合为：CFG = 7.0，Steps = 35**。在此参数链条下，不仅小舟、远山、迷雾完美对齐了古诗词的文化隐喻，且画面未出现形体坍塌与色彩溢出。

5 局部 Cross-Attention 提取与 LoRA 轻量化机制

5.1 Dreambooth 与 LoRA 轻量化微调数学原理

在任务（4）与任务（5）的系统监控中，全量微调（Full Fine-Tuning）暴露出了显存占用过高和高并发场景下的网络传输与权重加载瓶颈。为了在消费级硬件红线内实现高效的跨模态风格收敛，本节引入参数高效微调（PEFT）技术路线，重点探讨 **Dreambooth** 与 **LoRA（Low-Rank Adaptation, 低秩自适应）** 的数学协同机制。

5.1.1 Dreambooth 先验知识保持机制

Dreambooth 的核心贡献在于解决了极限小样本训练中的**灾难性遗忘**问题。它在目标函数中引入了一项**结构化先验知识保持损失（Prior Preservation Loss）**。

在微调“3D 粘土”或“水墨”风格时，系统不仅向 UNet 喂入带专属标签（如 `sks style`）的目标图像，同时并行抽取底模原生泛化生成的同类别图像（如普通的 `paintings`）作为对照组。其复合数学损失函数定义为：

$$L_{DB} = \mathbb{E}_{x, \epsilon, t} \left[\left\| \epsilon - \epsilon_{\theta}(z_t, t, C_{target}) \right\|_2^2 + \lambda \left\| \epsilon' - \epsilon_{\theta}(z'_t, t, C_{prior}) \right\|_2^2 \right]$$

其中， λ 为调节权重系数。该约束强行锁定了 UNet 对物理常识的通用认知骨架，允许大模型在“不把长河落日圆画成空间坍塌”的前提下，精准提取局部风格特征。

5.1.2 LoRA 低秩自适应增量矩阵公式

LoRA 的核心思想是：神经网络在特定任务下的权重更新具有极低的“**内在秩（Intrinsic Rank）**”。

因此，LoRA 选择完全冻结预训练 UNet 内部高达数十亿参数的主干权重矩阵 $W_0 \in \mathbb{R}^{d \times k}$ ，转而在其旁路并联一组由低秩分解构成的参数增量矩阵 ΔW 。

$$\Delta W = B \times A$$

其中， $B \in \mathbb{R}^{d \times r}$ ， $A \in \mathbb{R}^{r \times k}$ ，而核心超参数**秩 $r \ll \min(d, k)$** （本实验中将其设定为 $r = 8$ 或 $r = 16$ ）。

• 前向传播（Forward Pass）：

隐空间特征向量 x 在通过激活层时，前向计算公式线性演化为：

$$h = W_0 x + \Delta W x = W_0 x + \frac{\alpha}{r} (BA) x$$

其中， α 为缩放常数（Scaling Hyperparameter）。在训练启动时，矩阵 A 采用高斯分布初始化，矩阵 B 彻底清零，确保训练 Step 0 时的增量 $\Delta W = 0$ ，模型完全继承基底底模的固有能力。

• 参数量消减量化：

当核心维度 $d = k = 4096$ ，若秩 r 设为 8，全量微调所需的更新参数量为 $4096 \times 4096 = 16,777,216$ ；而改用 LoRA 后，更新参数量骤降为 $(4096 \times 8) + (8 \times 4096) = 65,536$ 。**参数优化计算量直接被消减了 256 倍。**

5.2 局部 Cross-Attention（交叉注意力）精准提取靶向策略

在工程落地中，若对 UNet 的所有模块（如 ResNet 卷积层、下采样层）盲目挂载 LoRA，依然会引发一定的显存冗余。本实验采取了**靶向定位策略**：锁定微调代码中的 `target_modules`，将低秩增量矩阵精确定位并插入至 UNet 内部的 **Cross-Attention（交叉注意力）** 组件中。

5.2.1 靶向挂载网络层名称

代码运行阶段，PEFT 钩子函数动态解析 UNet 的拓扑树状图，仅对以下四个跨模态注意力投影层实施动态拦截与注入：

- `to_q_lora`: 图像特征查询向量投影层（Query）

- to_k_lora: 文本语义键向量投影层 (Key)
- to_v_lora: 文本语义值向量投影层 (Value)
- to_out_lora: 注意力融合多头输出投影层 (Output)

5.2.2 局部 Cross-Attention 靶向微调的物理学机理

这种靶向注入机制的底层逻辑在于：Stable Diffusion v1.5 的常识空间、骨骼透视与像素线条主要由 ResNet Block 中的卷积层负责维系；而风格、材质、色彩分布以及跨模态的语义对齐，则完全由 Transformer Block 中的 Cross-Attention 算子锁死。

通过只针对 Q, K, V 投影层计算梯度，反向传播的能量得以精准聚焦于“如何让文本中的水墨/粘土词汇强行改变隐空间图文关联矩阵”这一核心矛盾上。这不仅斩断了显存暴血的根源，更由于未对 ResNet 伤筋动骨，从而在源头上锁死了基底模型的空间常识，根治了全量微调带来的“形体崩溃”恶性 Bug。

5.3 LoRA 风格强度因子 (Scale) 响应分析与最优值选取

在方案三 (Dreambooth + LoRA) 推理阶段，增量权重通过动态比例因子 S 耦合进原生 UNet 主干网络，其前向传播中的注意力交叉机制公式可表述为：

$$W_{effective} = W_{base} + S \cdot \Delta W = W_{base} + S \cdot (W_{up} \times W_{down})$$

其中 $S \in [0.0, 0.9]$ 。为了精确定位最优的风格迁移效能点，本研究针对水墨孤舟 (ink_boat) 与粘土钢铁侠 (clay_ironman, 包含大学习率调优前后两组) 实施了步长为 0.1 的全谱段消融测试。实验矩阵如 图 5-1、图 5-2 所示。




图 5-1 水墨画孤船风格因子测试图



图 5-2 粘土钢铁侠风格因子测试图

通过横向与纵向的微观语义比对，风格强度因子的动态响应曲线可清晰地划分为三个演变阶

段:

1. 欠拟合与特征游离阶段 ($S \in [0.0, 0.2]$)

- 水墨风格表现: 当 $S = 0.0$ 时, 画面完全退化为原生底模 **Baseline**, 展现出带有三维光影的现代写实景观。随着 S 递增至 0.2 , 画面开始出现微弱的宣纸泛黄质感, 但远山线条依然锋利, 小船骨骼仍残存现代数码绘画的硬边缘, 说明低秩矩阵的残差能量不足以扭转底模的强势先验。
- 粘土风格表现: 在此区间内, 钢铁侠的面具保持了极高的原生 **CG** 塑料或金属反光 (尤其在图 1 与图 2 的 $S = 0.1$ 处), 黏土特有的手工控制肌理 (如指纹凹凸感、哑光橡皮泥反光) 处于游离态, 未与主体形体发生深度卡合。

2. 帕累托最优平衡点 ($S = 0.3$ —— 黄金选取点)

- 水墨风格表现: 当 $S = 0.3$ 时, 模型达到了近乎完美的学术平衡。小船与远山的构图严格对齐了 **Baseline** 的几何空间分布, 但材质发生了戏剧性的流变: 线条演化为中国画地道的“墨分五色、浓淡相宜”, 背景晕染出了烟雨朦胧的留白意境, 且未发生任何结构病变。
- 粘土风格表现: 在两组粘土测试中, $S = 0.3$ 均表现出了极佳的风格化特质。在图 1 (低学习率) 中, 钢铁侠蜕变为饱满、圆润的软质单体泥塑手办, 背景也自适应为带有泥土手工感的褶皱底座; 在图 2 (大学习率调优后) 中, 面具精细度更高。更重要的是, 此时钢铁侠的头盔解剖解构 (如眼部、下巴) 非常精准, 无任何粘连崩溃, 完美实现了风格迁移与形体保护的解耦。

3. 过拟合与潜空间概念坍塌阶段 ($S \in [0.4, 0.9]$)

- 数据对比与病变: 当 S 越过 0.3 的临界点后, 低秩增量矩阵的能量开始反客为主, 对原生 **UNet** 的空间常识实施了“概念毁灭与绑架”。
 - 水墨风格 ($S \geq 0.6$): 空间解剖学彻底崩溃。 $S = 0.6$ 处画面退化为一个诡异的圆形抽象符号; $S = 0.7 \sim 0.9$ 时, 原本的孤舟与远山完全消失, 潜空间被高频、无序的杂乱墨迹和纸张褶皱 (**Fried Matrix**) 粗暴平铺, 去噪轨迹完全失控。
 - 粘土风格 ($S \geq 0.4$): 几何畸变灾难极其显著。在图 1 中, $S = 0.4$ 时钢铁侠的面具退化成了方块, $S = 0.7 \sim 0.8$ 时甚至异化为了类似高频网格或像素点的恐怖抽象几何; 在图 2 中, $S = 0.4$ 处的钢铁侠直接退化成了毫无线条的可怜秃头泥人, 而在 $S \geq 0.8$ 时, 由于能量过载, 模型甚至无法输出有效图像, 直接导致潜空间内容黑屏炸毁。

实验量化证实, **LoRA** 风格强度因子并非“越大越好”。过大的 **Scale** 会由于局部梯度的能量溢出, 导致交叉注意力机制丧失对核心提示词的空间位置定位能力。因此, 本研究最终将两种风格的推理 **Scale** 严格锁定为黄金阈值 $S = 0.3$ 。该参数在保障 100% 纯正水墨宣纸质感与哑光泥塑肌理的同时, 能完美保留基础模型的结构常识, 具有最强的鲁棒性与泛化度。

5.4 视觉效果定性分析

为了深入验证不同微调策略对生成质量的微观影响, 本研究对原生底模 (**Base Model Baseline**)、全参数微调 (**Full Fine-Tuning**) 与本研究提出的 **Dreambooth + LoRA** 轻量化架构 (**Ours**) 进行了多场景视觉定性评测。测试涵盖“写意水墨画”与“3D 粘土手办”两大跨模态风格, 生成结果分别如图 5-3 (水墨消融看板) 与图 5-4 (粘土消融看板) 所示。



图 5-3 水墨画风格对比图




图 5-4 粘土风格对比图

5.4.1 写意水墨风格定性分析：形体保持与意境晕染的博弈

在水墨风格测试中（图 5-3），通过对样本 (a) 奔马线与样本 (b) 孤舟线的横向解耦比对，可以得出以下结论：

1. Base 基准组（第 I 列）：原生底模在强写意提示词的驱动下，表现出了其固有的空间认

知。在样本 (a) 中, 马匹呈现出黑白相间的写实马匹骨骼, 但缺乏地道的宣纸晕染感; 在样本 (b) 中, 虽然构图带有东方山水画风, 但远山和建筑的边缘过于锐利, 带有明显的数字绘画光影痕迹。

2. Full 全参数微调组 (第 II 列): 全参数微调在极小样本的强行洗脑下, 展现出了严重的“概念绑架”与几何漂移。

在样本 (a) 中, 由于全量解冻了空间感知层, 底模原生的“花马”常识被完全抹杀, 强行扭转为一匹全黑的骏马, 且马蹄姿态发生了严重畸变。

在样本 (b) 中, 全量模型的解剖学崩溃更为显着: 原有的简洁山水构图被彻底篡改, 画面中央突兀地增殖出大量密集的复古中式建筑与杂乱小船, 产生了严重的过拟合冗余伪影, 失去了水墨画“以少胜多、计白当黑”的精髓。

3. Dreambooth+LoRA 组 (第 III 列, Ours): 在 $S = 0.3$ 的黄金控制点下, LoRA 展现出了完美的学术优越性。

像素级形体对齐: 纵向观察可知, LoRA 组生成的奔马姿态、动态线条以及小船和远山的宏观几何轮廓, 与第 I 列 Base 组实现了严格的像素级神隐对齐, 这有力地证明了冻结 UNet 主干能完美保护原生的空间常识与构图控制力。

纯正的纹理演变: 在完美保留构图的地基上, LoRA 优雅地吸收了训练集的水墨材质。马匹的毛发转化为灵动的泼墨线条, 背景呈现出极其地道的纸张纤维质感与墨迹扩散边缘, 山峦也完成了向写意留白意境的华丽蜕变。

5.4.2 3D 粘土风格定性分析: 逆向材质重构与形体崩溃

在 3D 粘土风格测试中 (图 5-4), 由于涉及从“硬质工业 CG”向“软质新手泥塑”的逆向材质重构, 三组模型的对抗表现更为剧烈:

1. Base 基准组 (第 I 列): 底模在看到“Claymation”词汇后, 展现出了基础的泥塑认知。但由于缺乏特定目标 (如钢铁侠、小狐狸) 的粘土手办概念, 样本 (a) 呈现出了一个带有诡异青绿色外壳、多眼、解剖结构扭曲的抽象机器人, 完全偏离了“钢铁侠”的标志性视觉符号; 样本 (b) 则画出了一只平滑度较低、毛发质感模糊的蓝白狐狸。
2. Full 全参数微调组 (第 II 列): 全参数微调再次展现出了“大力出奇效”但“完全失去空间控制”的特质。

灾难性的特征剥离: 在样本 (a) 中, FullFT 彻底抛弃了 Base 组的几何构图, 强制输出了一尊比例极为写实的工业级金属钢铁侠。虽然其材质和光泽极其逼真, 但完全丧失了“3D 橡皮泥手办”的软糯、哑光和手工感缺陷特征, 属于典型的“被训练集概念反向绑架, 导致风格迁移失败”。

在样本 (b) 中, 全量模型强行将狐狸的材质重写为极细致的仿真皮毛, 背景也扭转为了真实的泥土, 直接退化为了写实动物摄影, 丧失了粘土定格动画的艺术属性。

3. Dreambooth+LoRA 组 (第 III 列, Ours): Ours 组在此处贡献了全篇最亮眼的实验突破。

完美的常识融合: 在样本 (a) 中, LoRA 完美兼顾了 Base 组的“Q 版大头卡通构图”和训练集的“钢铁侠红黄核心配色”。它在 Base 组大头机器人的几何框架上, 巧妙地覆盖了饱和度极高的红黄粘土, 眼部转化为标志性的呆萌圆圈, 主体和背景展现出极其逼真的半哑光、带有微小手工瑕疵的橡皮泥肌理, 完美重构出了“定格动画手办”的微缩体量感。

在样本 (b) 中, LoRA 组的狐狸在姿态上与 Base 组保持 100% 同步, 但皮毛完全转化为由软质粘土捏制而成的片状手工质感, 眼部也自适应为反光圆润的粘土黑豆眼, 风格化能效极其显着。

5.5 实验结果量化分析

针对水墨风格与 3D 粘土风格在方案二 (UNet 全参数微调, FullFT) 与方案三 (Dreambooth+LoRA 旁路微调, Ours) 下的训练表现, 本研究从硬件内存开销、计算时效以及存储分发成本三个核心维度进行了量化评测。多指标消融对比结果如 图 5-5 所示。




图 5-5 训练量化指标对比图

5.5.1 动态峰值显存分析

实验日志表明，无论是水墨画风格还是 3D 粘土风格，全参数微调模式在训练过程中的动态峰值显存均高达 16.92 GB；而引入本研究设计的 Dreambooth + LoRA 旁路架构后，两种风格的动态峰值显存均被完美压制在 5.58 GB。

在深度学习的后向传播（Backpropagation）中，全参数微调解冻了 UNet 神经网络内的所有卷积层、残差块以及交叉注意力（Cross-Attention）通道，系统必须在显存中常驻并跟踪数亿个参数的梯度矩阵和优化器状态（如 AdamW 的一阶/二阶动量），从而触发了极高的动态显存峰值（接近 17 GB 硬件瓶颈）。相反，LoRA（Low-Rank Adaptation）技术严格冻结了原生 UNet 主干，仅在 48 个关键的 Cross-Attention 交互层外挂伴生低秩矩阵。后向传播时，显存只需计算并更新极其稀疏的旁路低秩权重，成功将硬件显存开销锐减 67.02%。

5.5.2 时间耗时分析

在累计训练耗时方面，水墨风格的 Full FT 与 LoRA 分别耗时 24.39 秒和 24.27 秒；而 3D 粘土风格的 Full FT 耗时 39.50 秒，其 LoRA 伴生模式耗时 27.77 秒。

水墨风格：由于两者的训练总轮次均为 10~15 轮且样本数极少（5 张），在算力充沛的 GPU 上，两者的训练总耗时几乎持平（约 24 秒），均展现出了极高的数据表征效率。

粘土风格：3D 粘土风格的全参数微调耗时显著拉长（39.50 秒），其主要原因在于“逆向材质重构”引发的梯度震荡。底模（SD v1.5）原生带有强烈的硬质工业高光和现代 CG 几何先验，全参数微调试图在全局权重上抹除这些先验并重写为半哑光、圆润的手工泥塑纹理，导致主干网络内多层非线性梯度在反向传播时出现相互拮抗与震荡，延长了收敛时间。而 LoRA 架构由于更新边界被低秩矩阵强行约束（Rank=8），消除了全局不确定性震荡，使反向梯度下降传导更加聚焦，从而在大幅增强粘土化质感的同时，缩短了 29.7% 的训练耗时。

5.5.3 模型体积分析

在模型导出体积这一指标上，全参数微调展现出了不可规避的“存储灾难”，导出的完整 UNet 风格化模型物理体积固定为 3.20 GB；而本研究导出的轻量化 LoRA 安全增量字典体积仅为 2.32 MB。

全参数微调的本质是对整个神经网络实施“全局洗牌”，其导出的产物是包含了全部 8.6 亿参数的重合权重文件，物理体积庞大。在实际的工业部署和多风格切换场景中，这意味着每增加一种风格，就需要额外分发并加载一个 3.2 GB 的独立大模型，会导致灾难性的带宽负载与内存冗余。而本研究采用的低秩自适应架构实现了全量地基与材质残差的物理级解耦。通过将高维矩阵更新（ ΔW ）降维分解为两个低秩矩阵的乘积（ $W_{up} \times W_{down}$ ），最终仅需保存这部分极其轻量化的增量参数。2.32 MB 与 3.20 GB 之间实现了超过 1400 倍的极限压缩比，使得风格组件化、即插即用、秒级热插拔分发成为了现实。

6 跨文化文本语义表征瓶颈与前置重构优化

6.1 CLIP 文本编码器的“文化失语症”机理分析

在本研究的“古诗转水墨画”跨模态生成任务中，除了主干网络（UNet）在材质迁移上面临的拟合挑战外，更深层的瓶颈源于文本潜在空间（Text Latent Space）的跨文化语义对齐断层。Stable Diffusion v1.5 底模内置的文本编码器（Text Encoder）采用的是 OpenAI 的 CLIP (ViT-L/14) 模型。从多模态对比学习（Contrastive Learning）的训练机理来看，该模型是在包含数亿英文图文对的西方主流数据集（如 LAION）上进行拉伸收敛的。这导致其在面对高内聚、多意象叠合、充满古典修辞隐喻的中国古典诗词时，存在天然的“文化失语症（Cultural Aphasia）”，具体表现在以下两个微观机制：

1. 多重隐喻的解调坍塌（Imagery Demodulation Collapse）

中国古诗词往往采用“意象并置”的手法（例如“孤舟蓑笠翁”）。在语言学中，这属于高度抽象的修辞隐喻。然而，CLIP 文本编码器在面对这类中文文本的字面直译时，其多头交叉注意力机制（Multi-Head Cross-Attention）无法在高维空间中将这些稀疏意象与视觉解剖结构正确卡合，导致去噪前向传播的早期轨迹（Early Trajectory）发生严重的语义漂移，常表现为主体丢失、构图混乱或产生概念错位伪影。

2. 潜在空间语义距离的错位（Latent Distance Misalignment）

在英文 CLIP 的双塔特征流形（Feature Manifold）中，词汇 Ink Wash Painting（水墨画）在向量欧氏距离上往往与“平面、单色边缘、写实东方商品元素”紧密耦合，而完全丧失了中国画中“意在画外”、“计白当黑”的宏观留白常识（Spatial Whitening Prior）。这导致模型在没有外在应用层干预的情况下，极难通过原诗句直接凝聚出空灵、淡雅的宣纸晕染意境。

6.2 基于大语言模型（LLM）的前置提示词解耦重构

为打破原版文本编码器的文化壁垒，本研究并未盲目追求高算力代价的文本端参数重新训练，而是提出了一个轻量化、敏捷的工程方案：引入大语言模型（LLM）作为前置提示词重构器（Front-end Prompt Restructurer）。

其核心策略在于：利用大语言模型强大的多语言泛化与概念展开能力，在前置阶段对中国古诗词实施“语义空间桥接（Semantic Space Bridging）”。LLM 将高度抽象、写意的古典意象进行视觉层面的解耦，转译为符合 CLIP 潜在空间高频认知、具象化的西方空间构图语言。提示词重构严格遵循“主体骨骼（Subject）- 物理环境（Environment）- 艺术材质（Style/Texture）- 宏观意境（Atmosphere）”的四维映射框架。

本研究在实际渲染管线中所采用的提示词流变重构矩阵如表 6-1 所示：

原始中国古诗词	意象视觉解耦与转换过程（LLM 内部推理）	LLM 重构提示词（CLIP 友好型全英文）
孤舟蓑笠翁，独钓寒江雪	① 提取核心主体：孤独的老渔夫、蓑衣、竹笠、小型木船 ② 提取物理环境：空旷平静的河流、漫天大雪、迷雾背 ③ 注入水墨材质：传统中国水墨、浓淡墨迹扩散、宣纸肌理 ④ 锁定的意境：绝对孤独、极简主义、大面积留白	A traditional Chinese ink painting, a single small wooden boat on a vast quiet river, a lonely old fisherman wearing a straw raincoat and bamboo hat, misty winter background, heavy snow falling, atmospheric, ink wash style, minimalism.

两岸猿声啼不住，轻舟已过万重山

① 提取核心主体：极其微小的木船、处于飞速行驶状态

② 提取物理环境：高耸入云的崇山峻岭、峡谷急流、云雾缭绕

③ 注入水墨材质：灵动的泼墨线条、动态飞溅的墨迹（Splatters）

④ 锁定的意境：轻快、雄浑磅礴、画外之境（Kinetic Sense）

Traditional Chinese ink wash illustration, a tiny fast-moving wooden boat speeding through a narrow river canyon, majestic and towering mountains covered in mist, kinetic brushstrokes, expressive ink splatters, sense of high speed and relief.

6.3 双案例提示词消融实验结果定性分析

为了直观验证前置提示词重构方案对跨文化语义对齐的实际贡献，本研究引入控制变量法，分别以《江雪》（静态、留白意境）与《早发白帝城》（动态、宏大意境）两首视觉差异极大的古典诗词作为核心测试案例。

三组实验在完全相同的原生底模（Stable Diffusion v1.5 Base Model）及物理随机种子（Seed=42）下展开，以确保文本表征（Text Representation）为全流程生成的唯一变量。消融测试矩阵如 图 6-1（Text Encoder Ablation Grid）所示。



图 6-1 文本表征测试矩阵图

第一行：案例一《江雪》（左：中文直输 | 中：机器直译 | 右：LLM 重构）

第二行：案例二《早发白帝城》（左：中文直输 | 中：机器直译 | 右：LLM 重构）

通过对图 6-1 展开横向与纵向的微观语义解剖，不同文本处理策略引发的去噪轨迹呈现出显著的艺术分化与病理学特征。

6.3.1 案例一《江雪》语义流变定性解构

1. 中文文本直输组（图 6-1 左上）：画面呈现出高度写实的现代红木连廊建筑与极其规整的冬季积雪，构图极度饱满。该图展现出了原版 CLIP 文本编码器典型的“文化失语症”。模型完全无法理解“孤舟蓑笠翁”的修辞隐喻，而是提取了汉字被切碎后的碎片化编码。在缺乏东方文化先验的前提下，去噪管线完全倒向了西方互联网数据集中最常见的“冬季古建雪景（Snowy Architecture）”高频聚类分布，引发了语义塌陷。
2. 字面直译机器组（图 6-1 中上）：画面精准捕获到了“木船（Boat）”与“戴斗笠、穿雨衣的人”，但画面整体呈现为一幅高度写实、光影锋利的高清欧美风竹林写生摄影。这有力地印证了“字面直译的语义距离错位”。直译英文虽激活了对应的物理标签，但由于缺乏艺术材质与宏观意境的显式约束，CLIP 在高维潜空间中直接将其归类到了西方摄影流形中，彻底丧失了中国山水画“气韵生动”的写意感。
3. LLM 视觉解耦重构组（图 6-1 右上，本文方案）：画面发生了戏剧性的蜕变。现代写实建筑与欧美写生竹林完全隐去，取而代之的是一幅正宗的中国传统写意水墨画。江面大面积空灵留白，近处孤舟寒蓑形体极其精确，远山在烟雨飞雪中呈现出朦胧隐退的东方美学。这证明了四维解耦策略的卓越性，成功引导模型在去噪早期阶段锁定写意先验。

6.3.2 案例二《早发白帝城》语义流变定性解构

1. 中文文本直输组（图 6-1 左下）：画面发生了灾难性的“潜空间表达异化”，竟然直接生成了一整幅密密麻麻、类似拓片或古代小篆拓印字帖的书法残卷图，完全丧失了图像生成的空间常识。这一极端的实验结果极具学术价值。它极其确凿地证明了：当原版 CLIP 面对极为内聚、在西方语料中缺乏视觉对齐的纯中文古典诗句（如“两岸猿声啼不住”）时，其文本特征矩阵在映射中发生了空间混乱与能量过载。模型误以为用户的意图是“生成汉字书法或古代拓片本身”，从而在潜空间中完全迷失了物体空间定位，退化为高频的乱码字帖伪影。
2. 字面直译机器组（图 6-1 中下）：画面渲染出了一艘巨大的、带有复杂双风帆的西式木质大帆船，在波涛汹涌的宽阔海面上行驶，画风极度偏向 19 世纪欧洲古典铜版画或黑白木刻版画风格。这揭示了跨文化直译带来的“严重语义漂移”。直译提示词中的 light boat（轻舟）被 CLIP 错误地解码为了西方大航海时代背景下的远洋战舰构图，材质也直接被欧洲插画的密集排线纹理绑架，完全偏离了三峡峡谷急流的东方意境。
3. LLM 视觉解耦重构组（图 6-1 右下，本文方案）：画面再次贡献了极其惊艳的突破。西式大帆船与版画排线完全消失，画面中央凝聚出了一艘极其轻灵、符合原诗意境的中式独木轻舟。两侧高耸入云的崇山峻岭重峦叠嶂，云雾缭绕。更重要的是，山峦的线条呈现出极其纯正的中国画“斧劈皴”与泼墨飞溅（Splatters）笔触，完美传达了轻舟顺流而下的动感与速度感，使“轻舟”与“万重山”在多模态潜空间中达成了无损的文化交融。

6.4 物理替换文本编码器（Chinese-CLIP / AltDiffusion）的可行性论证

为了进一步探索底层的学术边界，本研究进一步针对“直接在架构层面物理替换文本编码器”这一硬核路线进行了严谨的技术可行性论证：

6.4.1 数学层面的特征对接（Dimension Matching）

原生 Stable Diffusion v1.5 的 UNet 交叉注意力层接收的文本特征矩阵维度固定为：

$$\mathbf{F}_{\text{text}} \in \mathbb{R}^{B \times 77 \times 768}$$

其中 B 为 Batch Size，77 为最大 Token 序列长度，768 为 Embedding 隐藏维度。

若要将原装文本编码器物理拆卸，换用专门针对中文多模态优化的 Chinese-CLIP（阿里开源）或基于多语言共振空间的 AltDiffusion (X-CLIP 架构)，新编码器必须在前向传播中通过线性投影（Linear Projection）将输出特征的最后一维对齐至 768，并重写 Tokenizer 的截断逻辑，以保证与 UNet 主干中交叉注意力键矩阵（Key Matrix）和值矩阵（Value Matrix）的拓扑匹配。

6.4.2 中文艺术先验的物理激活

从理论上讲，Chinese-CLIP 在海量原生中文电商及艺术图文对上实施了对比拉伸。在其潜在空间中，“宣纸、泼墨、皴法、留白”等词汇的特征向量距离（Cosine Similarity）与真实中国艺术画作的图像特征天生高度凝聚。若能成功替换，用户直接输入中文古诗，UNet 即可直接在第一阶段调用最纯正的中国画构图常识。

6.5 工程折衷（Trade-off）与技术决断

然而，在实际工程实操与资源受限（本地单卡 16GB VRAM 限制）的前提下，直接物理替换文本编码器会引发严重的“表征断层（Representation Disalignment）”灾难。

由于原模型的 UNet 主干在数十亿步的预训练过程中，已经完全熟悉并锁定路标了原版英文 CLIP 的“特征向量方言”。当骤然将原配编码器拔除、换入全新的中文编码器时，文本流形空间的几何分布发生了完全不连续的剧烈偏移。此时，UNet 主干面对换装后的全新文本向量将陷入完全无法识别的“听不懂”状态。

要修复这一表征断层，必须解冻整个 UNet 的所有空间层，配合中文编码器重新实施代价极其高昂的全局多模态联合对齐训练。在仅有 5 张小样本训练集且显存预算受限的微观场景下，强行替换文本编码器会导致前向去噪轨迹彻底失控，生成画面退化为无序的色块噪点（Fried Latent）。

装

订

线

7 总结

本研究以中华优秀传统文化数字化传承为导向，围绕“古诗转水墨画”这一核心任务，系统开展了基于 Stable Diffusion v1.5 的文生图模型部署、多策略微调、推理优化、轻量化改进与跨文化语义对齐研究。通过全量微调、参数高效微调、超参数消融实验、提示词工程优化及硬件开销对比等完整实验链路，形成了一套低资源、高可控、艺术保真的古典诗词意境可视化生成方案。

实验首先完成了模型在 AutoDL 算力平台的离线部署与文生图全流程验证，明确了 VAE、CLIP 文本编码器、UNet 与采样调度器的协同工作机制。针对传统水墨与 3D 粘土两种视觉风格，构建小样本异构数据集并实施 UNet 全量微调，在实现强风格迁移的同时，揭示了其显存占用高、模型体积大、易出现灾难性遗忘与形体崩溃等工程局限。

为解决上述问题，本研究引入 DreamBooth + LoRA 轻量化微调架构，仅对 UNet 交叉注意力层注入低秩增量矩阵，在保持生成质量的前提下，将动态峰值显存从 16.92 GB 降至 5.58 GB，模型存储体积由 3.20 GB 压缩至 2.32 MB，实现了显存开销、训练时效与部署成本的全面优化。通过风格强度因子消融实验，确定最优风格强度 $Scale=0.3$ ，达成风格迁移与结构保真的平衡。

同时，针对原生 CLIP 编码器对中国古诗词存在的文化语义断层问题，提出基于大语言模型的前置提示词解耦重构策略，将古典意象转化为符合跨模态模型认知的构图语言，显著提升生成画面的意境契合度与艺术规范性。综合对比表明，“LLM 提示词增强 + LoRA 轻量化微调”方案可在消费级硬件条件下稳定输出构图合理、笔墨纯正、意境完整的水墨画作品。

本研究实现了深度学习技术与传统水墨艺术的有效结合，验证了参数高效微调在小样本风格化任务中的优越性，为古典文化意象的数字化生成、轻量化部署与工业级落地提供了可复用的技术路径与实践参考。